

Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

Estimación de parámerros epidemiológicos dependientes del tiempo mediante el Filtro de Kalman por Ensamble en el modelo SIRD

Tesis presentada al

Posgrado de Investigación en Ciencia de Datos

como requisito parcial para la obtención del grado de

Maestro en Investigación en Ciencia de Datos

por

Marcos Bautista Muñoa

Asesorado por

Dra. Beatriz Bonilla Capilla

Puebla Pue.
11 de noviembre de 2026



Benemérita Universidad Autónoma de Puebla

Facultad de Ciencias Físico Matemáticas

Estimación de parámerros epidemiológicos dependientes del tiempo mediante el Filtro de Kalman por Ensamble en el modelo SIRD

Tesis presentada al

Posgrado de Investigación en Ciencia de Datos

como requisito parcial para la obtención del grado de

Maestro en Investigación en Ciencia de Datos

por

Marcos Bautista Muñoa

Asesorado por

Dra. Beatriz Bonilla Capilla

Puebla Pue.
11 de noviembre de 2026

Título: Estimación de parámerros epidemiológicos dependientes del tiempo mediante el Filtro de Kalman por Ensamble en el modelo SIRD
Estudiante: Marcos Bautista Muñoa

COMITÉ

Dr. Jorge Velzaquez Castro
Presidente

Dr. Erique Varela Carlos
Secretario

Dr. Ivan Fuentecilla Carcamo
Vocal

Vocal

Dra. Beatriz Bonilla Capilla
Asesor

Índice general

1. Introducción **1**
1.1. Objetivos 1
1.2. Justificación 1

2. Epidemias **3**
2.1. ¿Cómo se comporta una epidemia? 4
2.2. El modelo SIRD 4

3. Procesos estocásticos y propiedad de Markov (Marco Teorico) **7**
3.1. cadenas de Markov 7
3.2. Suavizadores Bayesianos 8
3.3. Filtros de kalman 8
3.4. Filtros de kalman por conjuntos 8

4. Datos **9**
4.1. Archivos CSV 10
4.1.1. Estructura de la base de datos 10
4.1.2. Catálogos normativos 10
4.2. Cambios metodológicos y exploración de los datos 13

5. Metodologia **15**

Bibliografía **17**

Capítulo 1

Introducción

En diversas situaciones, cuando se intenta llevar la teoría a la práctica, y sobre todo cuando esta se desarrolla en el mundo físico, es necesario considerar una gran cantidad de situaciones distintas. Esto ocurre al estudiar una epidemia. Aunque existen muchos modelos matemáticos que describen su evolución y comportamiento, es necesario incorporar cada vez más variables para estimar de forma más precisa la situación real a la que se enfrenta la población.
La pandemia de COVID-19 es un claro ejemplo de ello. Si se tuviera una idea fiable de cómo se desarrolla una epidemia, se podrían diseñar políticas públicas realmente útiles.
Esta es una tarea difícil, ya que en el modelo SIRD (susceptibles, infectados, recuperados y fallecidos) normalmente se toman los parámetros de la epidemia como constantes, aun cuando estos pueden cambiar con el tiempo debido a factores como las medidas sanitarias, el comportamiento de la población o la aparición de nuevas variantes.

1.1. Objetivos

Estimar los parámetros β, γ y δ, (tasa de contagio, tasa de recuperación y tasa de mortalidad, respectivamente) dependientes del tiempo, del modelo SIRD mediante el método de ensamble de los filtros de Kalman, a partir de datos sobre COVID-19 en México.

1.2. Justificación

Los filtros de Kalman de ensamble (EnKF, por sus siglas en inglés) son una técnica de asimilación de datos diseñada para estimar estados y parámetros en sistemas dinámicos, especialmente cuando estos son no lineales y están sujetos a incertidumbre. A diferencia del filtro de Kalman clásico, el EnKF utiliza un conjunto de simulaciones (ensamble) para representar la distribución de probabilidad del sistema, lo que permite capturar de manera más flexible la variabilidad y el ruido en los datos. Este enfoque combina las predicciones del modelo con observaciones reales mediante actualizaciones secuenciales, ajustando continuamente las estimaciones conforme se dispone de nueva información.

Capítulo 2

Epidemias

A lo largo de toda nuestra historia como especie, nos hemos enfrentado a problemas de salud, dentro de los cuales los virus y las bacterias han sido parte fundamental de estas situaciones. No importa cuánto logremos desarrollar la medicina: así como nosotros evolucionamos como especie, también lo hace nuestro ambiente, por lo que estamos en una lucha constante por sobrevivir.

Recientemente, el mundo se enfrentó a la pandemia de COVID-19, un evento que impactó al mundo entero y que, a pesar de todo el conocimiento que se tiene sobre el área, vino a demostrar que es necesario seguir desarrollando temas epidemiológicos para poder afrontar este tipo de problemas.

Es importante notar que este evento no ha sido el único del que tenemos registro. Desde la antigüedad, la humanidad se ha enfrentado a diversas epidemias, siendo una de las más antiguas de las que se tiene registro la plaga de Atenas, que data aproximadamente de los años 430 a 426 a. C.

Fue gracias a Tucídides, militar e historiador ateniense, que se tiene un registro detallado de lo ocurrido en esta epidemia. Él fue quien recabó distinta información sobre la enfermedad que azotó al pueblo ateniense, registrada en un texto en el que se lee:

> «Descrito con gran detalle [...] incluidos los síntomas y la progresión de la enfermedad. También dio algunas cifras exactas, como que 1050 de 4000 soldados en una expedición murieron a causa de la enfermedad. La enfermedad descrita tan minuciosamente por Tucídides, incluso hasta el hecho de que los perros que comieron los cadáveres también sufrieron, ha sido la fuente de numerosos artículos durante cientos de años con casos presentados (con gran convicción y defendidos vehementemente) para un increíble rango de enfermedades».[3]

Otro caso, posiblemente el más famoso después del COVID-19, es el de la peste negra, la cual:

> «se convirtió en una pandemia de tal magnitud que no solo sacudió los cimientos económicos y sociales del Viejo Mundo, sino que cambió el curso de la historia. Tuvo su origen en Asia, se propagó a Europa, y su influencia llegó hasta el norte de África. El contagio llegó por barco, pues en aquellos tiempos empezaron a abrirse nuevas rutas de intercambio, ya que Europa empezaba a tener un avance económico y comercial».[2]

Se estima que la peste negra causó entre 75 y 200 millones de muertes en el mundo, mientras que en Europa murió entre el 30 % y el 60 % de la población.

Estos y demás ejemplos que podemos seguir tratando nos dan una idea de por qué es importante estudiar este tipo de fenómenos, ya que las implicaciones sociales, culturales, entre otras, son de gran relevancia para el bienestar colectivo.

2.1. ¿Cómo se comporta una epidemia?

Ahora que tenemos el contexto sobre la importancia de estudiar las epidemias, podemos plantearnos varias preguntas que nos ayudarán a abordar esta área.
Definamos los siguientes conceptos, que nos darán la pauta para establecer las reglas que seguirá nuestro estudio.
Una epidemia es "cuando el número de casos de una enfermedad excede lo esperado en una comunidad, región o país, donde se especifican claramente la región geográfica y el periodo temporal" [5].
Una infección, en términos generales, es "la invasión de un organismo por parte de otro más pequeño" [7]. Con esta definición podemos hacer referencia no únicamente a los casos de enfermedades en humanos, sino también a que la infección es una situación común en la naturaleza.
Entonces, lo importante es entender la dinámica de una pandemia. Con lo definido anteriormente, se trata de preguntarnos cómo ocurre la transición del estado de una persona no infectada a un estado de infectada, y esto a gran escala.
Dada la naturaleza de la enfermedad que se estudia, la cantidad de suposiciones que se tomarán en cuenta es considerable, ya que no es posible tratar todos los casos de la misma manera. Los modelos clásicos trabajan a partir de una cantidad fija de personas susceptibles, por lo que casos como nacimientos o muertes que no sean causados por la enfermedad no se contabilizan.
Esto nos lleva a preguntarnos: ¿cuál es la metodología para elegir un modelo apropiado? Para responderla, debemos analizar las características de nuestro caso de estudio e identificar cuáles son cruciales y cuáles podemos dejar de lado. En el caso de las enfermedades, algunas de las preguntas que podemos plantearnos para establecer el modelo son:

- ¿Es muy contagiosa esta enfermedad?
- ¿La enfermedad tiene una alta mortalidad?
- ¿Quiénes son propensos a contraer la enfermedad?
- ¿Qué tan rápido se desarrolla la enfermedad en una persona?
- Una persona infectada, ¿cuánto tiempo tiene la enfermedad?

A partir de las preguntas adecuadas y del objetivo del estudio, se puede elegir un modelo correcto. Dependiendo de los objetivos, podemos optar entre un modelo determinista o uno estocástico. Los modelos deterministas incluyen información sobre los promedios de lo que sucede en la población. Por otro lado, los modelos estocásticos incorporan la aleatoriedad del proceso y nos brindan información numérica sobre las transiciones entre diferentes compartimentos.
La mayoría de los modelos deterministas son comúnmente llamados modelos compartimentales. Estos dividen la población en subgrupos y, mediante sistemas de ecuaciones diferenciales, se aproxima la cantidad de personas que se encuentran en cada subgrupo. Para ello, el tiempo se discretiza en pasos, generalmente de un día, lo que permite obtener la aproximación del tiempo $t+1$ en términos de lo que se tiene en t.

2.2. El modelo SIRD

El modelo SIRD es un modelo compartimental en el que se divide una población total N (constante) en cuatro compartimientos:

- Susceptibles (S)
- Infectados (I)
- Recuperados (R)

- Fallecidos (D)

Cabe notar que, a diferencia de modelos como SIR o SEIR, aquí se toman en cuenta las personas fallecidas, ya que la mortalidad registrada durante la pandemia de COVID-19 fue considerable y no es posible despreciarla.
Además, estos compartimientos seguirán las siguientes reglas para el estudio que se presentará más adelante:

- El compartimiento de susceptibles incluye a cualquier persona que pueda ser infectada.
- El compartimiento de infectados incluye a cualquier persona que tenga la enfermedad, esté infectada y pueda transmitirla. Aquí entran los casos comunes de infección, pero también los casos asintomáticos, que en algunas ocasiones pueden incluso no tener registro.
- El compartimiento de recuperados incluye a las personas que sobrevivieron y salieron del compartimiento de infectados. Además, se supone que al recuperarse se adquiere inmunidad hacia la enfermedad, por lo que la probabilidad de que una persona recuperada pase a ser susceptible es nula.

En este modelo, la dinámica de transición entre los compartimientos, dependiente del tiempo, se define de la siguiente manera, con $N = S(t) + I(t) + R(t) + D(t)$:

$$\frac{dS}{dt} = -\beta I \frac{S}{N} \tag{2.1}$$
$$\frac{dI}{dt} = \beta I \frac{S}{N} - \gamma I - \delta I \tag{2.2}$$
$$\frac{dR}{dt} = \gamma I \tag{2.3}$$
$$\frac{dD}{dt} = \delta I \tag{2.4}$$

Los parámetros que aparecen en las ecuaciones diferenciales son los encargados de modificar el comportamiento de la propagación de la enfermedad:

- β (beta): tasa de contagio. Controla qué tan rápido los susceptibles se infectan y depende del contacto social y de la probabilidad de transmisión.
- γ (gamma): tasa de recuperación. $\frac{1}{\gamma}$ es el tiempo promedio de recuperación.
- δ (delta): tasa de mortalidad. $\frac{1}{\delta}$ es el tiempo promedio hasta el fallecimiento desde la infección.

Estos parámetros se toman como fijos, pero en la realidad no lo son: las distintas medidas o políticas públicas que se apliquen, así como el avance del conocimiento médico, afectan directamente su valor.
Ahora, conociendo lo que representa cada uno de los parámetros β, γ y δ, es fácil entender lo que describen las ecuaciones diferenciales. Sabemos que la derivada representa el cambio respecto a algo, que en este caso es el tiempo. Cada una de las ecuaciones nos dice cómo cambia el número de individuos en ese compartimiento con respecto al tiempo.
En el caso de los susceptibles, la cantidad de personas únicamente puede disminuir, razón por la cual aparece el signo menos. Además, estas personas salen de este compartimiento según la proporción de infectados y susceptibles respecto a la población total.
Por otro lado, las personas que salen del compartimiento de susceptibles son las mismas que entran al compartimiento de infectados, por eso el término se traslada directamente. Además, de este compartimiento hay dos vías de salida: la recuperación o la muerte.
Los dos últimos compartimientos son relaciones directas de lo anterior.

Estos parámetros, en los modelos clásicos, pueden tomarse como constantes; sin embargo, cuando se busca aplicarlos a un problema a gran escala y en tiempo real, dejan de serlo, ya que diversas acciones, como la aplicación de políticas públicas, el avance en el conocimiento de la enfermedad y el pánico mismo de la población, afectan directamente el valor de dichos parámetros. Con este modelo, ahora podemos hacer estimaciones resolviendo numéricamente el sistema de ecuaciones. Esta resolución nos dirá cómo va avanzando la epidemia, dependiendo de los valores iniciales que nosotros coloquemos, además de los valores de los parámetros γ, β y δ. Toda esta estimación será nuestra creencia.

Capítulo 3

Procesos estocásticos y propiedad de Markov (Marco Teorico)

/sectionProcesos estocastcos

3.1. cadenas de Markov

Para llegar al procedimiento de Filtros de Ensambles de Kalman, observemos antes la teoría básica y cómo llegamos hasta ese tema. Definamos nuestro espacio de trabajo y desarrollemos paso a paso.
En un tiempo discreto, consideremos un espacio contable I. Llamemos a cada $i \in I$ un estado, por lo que I será el espacio de estados. Además, podemos realizar una medición para cada $i \in I$. Entonces, $\lambda = (\lambda_i : i \in I)$ es una medida en I si $0 \leq \lambda_i < \infty$ para todo $i \in I$. Si además la masa total cumple $\sum_{i \in I} \lambda_i = 1$, llamamos a λ una distribución. Todo esto lo trabajamos a través de un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.
Si X es una variable aleatoria con valores en I, entonces es una función $X : \Omega \to I$. Suponemos que

$$\lambda_i = \mathbb{P}(X = i) = \mathbb{P}(\{\omega \in \Omega : X(\omega) = i\}),$$

lo que nos dice que λ define la distribución de X. Así, X modela un estado aleatorio que toma el valor i con probabilidad λ_i.
Ahora, si definimos una matriz $P = (p_{ij} : i, j \in I)$, decimos que es estocástica si cada fila es una distribución. Algunas veces, una representación gráfica de esta matriz ayuda a entender mejor lo que estamos definiendo. Un ejemplo puede verse en la siguiente figura:
Con lo definido anteriormente, enunciamos la definición de cadena de Markov.
Definición. Decimos que $(X_n)_{n \geq 0}$ es una cadena de Markov con distribución inicial λ y matriz de transición P si:

(i) X_0 tiene distribución λ;

(ii) para $n \geq 0$, condicionalmente a que $X_n = i$, X_{n+1} tiene distribución $(p_{ij} : j \in I)$ y es independiente de $X_0, \ldots, X_{n-1}$ [4].

La primera característica define el estado inicial y especifica las probabilidades de que el sistema comience en cada uno de los estados posibles en el tiempo cero.
La segunda característica combina dos propiedades fundamentales: la pérdida de memoria y la homogeneidad temporal.

La pérdida de memoria es una propiedad base de las cadenas de Markov. Indica que la distribución del estado futuro depende únicamente del estado actual y es independiente de toda la historia pasada. De forma matemática,

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \ldots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij}.$$

La homogeneidad temporal se refiere al elemento p_{ij}, que indica la probabilidad de transitar del estado i al estado j. Esta probabilidad depende únicamente de la pareja de estados (i, j) y no del instante n en el que nos encontremos.

3.2. Suavizadores Bayesianos

3.3. Filtros de kalman

3.4. Filtros de kalman por conjuntos

Capítulo 4

Datos

La información con la que se trabajó en esta investigación es muy variada: desde artículos y publicaciones que se enfocaron en puntos clave, los cuales ayudaron a tomar decisiones sobre cómo proseguir con la investigación, hasta la columna vertebral del análisis, que son los registros públicos de cada persona reportada en México.
En México, la Dirección General de Epidemiología (DGE), órgano normativo de la Secretaría de Salud del Gobierno de México, tiene como función principal dirigir la vigilancia epidemiológica, el análisis de datos de salud pública y la investigación nacional. Esta tarea se lleva a cabo mediante el Sistema Nacional de Vigilancia Epidemiológica (SINAVE), el cual es un conjunto de estrategias, acciones y plataformas que estandariza la recopilación de información proveniente de distintas instituciones de salud, tales como el IMSS, el ISSSTE, Pemex y los hospitales privados, permitiendo que la información fluya desde las comunidades más aisladas hasta las oficinas generales de la DGE. Asimismo, se considera lo establecido en el decreto en materia de datos abiertos:

> "Que el Decreto que establece la regulación en materia de Datos Abiertos publicado en el Diario Oficial de la Federación el 20 de febrero de 2015, tiene el objeto de regular la forma mediante la cual los datos de carácter público, generados por las dependencias y entidades de la Administración Pública Federal, y las empresas productivas del Estado, se pondrán a disposición de la población como datos abiertos, con el propósito de facilitar su acceso, uso, reutilización y redistribución para cualquier fin, conforme a los ordenamientos jurídicos aplicables" [1].

Contamos con los registros de COVID-19 de los años 2020, 2021, 2022 y 2023. Estos serán los únicos años considerados en el análisis, ya que delimitan el periodo comprendido entre:

- La confirmación de los primeros casos en México, el 27 de febrero de 2020.
- La publicación del decreto por el que el Gobierno de México da por terminada la emergencia sanitaria por COVID-19, el 9 de mayo de 2023.

Dentro de este rango de fechas se destacan seis olas de importancia:

- Primera ola: semanas epidemiológicas 8 a 39 de 2020 (marzo a septiembre de 2020).
- Segunda ola: semanas epidemiológicas 40 de 2020 a 15 de 2021 (octubre de 2020 a abril de 2021), con pico de mortalidad en enero de 2021.
- Tercera ola: semanas epidemiológicas 23 a 42 de 2021 (junio a octubre de 2021), impulsada por la variante Delta.

- Cuarta ola: semanas epidemiológicas 51 de 2021 a 9 de 2022 (diciembre de 2021 a marzo de 2022), impulsada por la variante Ómicron y con pico máximo de contagios en enero de 2022.
- Quinta ola: semanas epidemiológicas 22 a 33 de 2022 (mayo a agosto de 2022).
- Sexta ola: semanas epidemiológicas 49 de 2022 a 4 de 2023 (diciembre de 2022 a enero de 2023) [6].

4.1. Archivos CSV

Los datos utilizados provienen de archivos en formato CSV proporcionados por la institución. Para su correcta interpretación, se distinguen dos componentes: la base de datos, que contiene los registros de cada persona reportada, y los catálogos normativos, que definen el significado de los códigos numéricos que aparecen en dicha base. Ambos componentes se describen a continuación.

4.1.1. Estructura de la base de datos

Los metadatos que proporciona la institución (archivo `Descriptores`) indican que la base de datos consta de 41 variables activas, las cuales se agrupan en las siguientes categorías de información:

- **Identificación y temporalidad:** `FECHA_ACTUALIZACION`, `ID_REGISTRO`, `FECHA_INGRESO`, `FECHA_SINTOMAS` y `FECHA_DEF`.
- **Demografía y ubicación:** `SEXO`, `EDAD`, `NACIONALIDAD`, `ENTIDAD_UM`, `ENTIDAD_NAC`, `ENTIDAD_RES`, `MUNICIPIO_RES`, `PAIS_NACIONALIDAD`, `PAIS_ORIGEN` y la variable `MIGRANTE`.
- **Inclusión social:** evaluación de pertenencia mediante `INDIGENA` y `HABLA_LENGUA_INDIG`.
- **Comorbilidades y condiciones previas:** indicadores dicotómicos (`SI_NO`) sobre `EMBARAZO`, `NEUMONIA`, `DIABETES`, `EPOC`, `ASMA`, `INMUSUPR`, `HIPERTENSION`, `CARDIOVASCULAR`, `OBESIDAD`, `RENAL_CRONICA`, `TABAQUISMO` y `OTRA_COM`.
- **Manejo clínico y severidad:** `ORIGEN` (USMER / No USMER), `SECTOR` (institución de atención), `TIPO_PACIENTE` (ambulatorio / hospitalizado), `INTUBADO` e ingreso a `UCI`.
- **Laboratorio y diagnóstico:** `TOMA_MUESTRA_LAB`, `RESULTADO_PCR`, `RESULTADO_PCR_COINFECCION`, `TOMA_MUESTRA_ANTIGENO` y `RESULTADO_ANTIGENO`.
- **Clasificación epidemiológica final:** `CLASIFICACION_FINAL_COVID` y `CLASIFICACION_FINAL_FLU`.

Cada registro corresponde a una persona reportada, y gran parte de sus variables toma valores codificados de forma numérica. Por ello, la interpretación de dichos valores requiere los catálogos que se describen en la siguiente subsección.

4.1.2. Catálogos normativos

El archivo de catálogos cuenta con 13 pestañas de estandarización. Para facilitar su lectura, los catálogos se presentan agrupados por tema.

Diagnósticos por laboratorio y clasificación final

- **Catálogo** `RESULTADO_PCR` **(35 claves):** codifica la detección por PCR de patógenos específicos: influenza (`AH1N1 PMD`, `A H1`, `A H3`, `B`, `H5`), `SARS-CoV-2`, coronavirus humanos (`229E`, `OC43`, `NL63`, `HKU1`, `MERS-CoV`), virus sincicial respiratorio (`VSR A/B`), parainfluenza, adenovirus, metapneumovirus, bocavirus y enterovirus/rinovirus, además de estatus de control analítico.
- **Catálogo** `RESULTADO_ANTIGENO`**:** define los resultados de pruebas rápidas (`1: Positivo a SARS-CoV-2`, `2: Negativo`, `97: No aplica`).
- **Catálogo** `CLASIFICACION_FINAL_COVID`**:** establece el dictamen epidemiológico en 7 niveles (asociación clínica, dictaminación, laboratorio positivo, inválido, no realizado, sospechoso y negativo).
- **Catálogo** `CLASIFICACION_FINAL_FLU`**:** determina el dictamen epidemiológico para influenza en 5 niveles.

Sector sanitario y geografía

- **Catálogo** `SECTOR`**:** especifica la institución (Cruz Roja, DIF, Estatal, IMSS, IMSS-Bienestar, ISSSTE, Municipal, PEMEX, Privada, SEDENA, SEMAR, SSA, Universitario, CIJ, IMSS Bienestar OPD y No especificado).
- **Catálogos geográficos (**`ENTIDADES` **y** `MUNICIPIOS`**):** mapean numéricamente las 32 entidades federativas de la República Mexicana y sus respectivos municipios.
- **Catálogos generales:** codificación estandarizada para `ORIGEN`, `SEXO`, `TIPO_PACIENTE`, `NACIONALIDAD` y respuestas binarias o de control (`SI_NO`).

Variables categóricas generales y sociodemográficas

A continuación se detallan los valores admisibles para cada variable categórica del catálogo normativo.

- **ORIGEN** (tipo de vigilancia):
  - `1`: USMER (Unidades de Salud Monitoras de Enfermedades Respiratorias)
  - `2`: FUERA DE USMER
  - `99`: NO ESPECIFICADO
- **SECTOR** (institución de atención):
  - `1`: CRUZ ROJA | `2`: DIF | `3`: ESTATAL | `4`: IMSS | `5`: IMSS-BIENESTAR | `6`: ISSSTE | `7`: MUNICIPAL | `8`: PEMEX | `9`: PRIVADA | `10`: SEDENA | `11`: SEMAR | `12`: SSA | `13`: UNIVERSITARIO | `14`: CIJ | `15`: IMSS Bienestar OPD | `99`: NO ESPECIFICADO
- **SEXO**:
  - `1`: MUJER | `2`: HOMBRE | `99`: NO ESPECIFICADO
- **TIPO_PACIENTE**:
  - `1`: AMBULATORIO | `2`: HOSPITALIZADO | `99`: NO ESPECIFICADO
- **NACIONALIDAD**:
  - `1`: MEXICANA | `2`: EXTRANJERA | `99`: NO ESPECIFICADO

- **SI_NO** (aplicable a comorbilidades, síntomas, intubación, UCI y variables binarias):
  - 1: SÍ | 2: NO | 97: NO APLICA | 98: SE IGNORA | 99: NO ESPECIFICADO
- **ENTIDAD_UM / ENTIDAD_NAC / ENTIDAD_RES**:
  - Claves numéricas del 1 al 32 (correspondientes a las 32 entidades federativas), 36 (Estados Unidos Mexicanos), 97 (No aplica), 98 (Se ignora) y 99 (No especificado).

Pruebas diagnósticas y resultados de laboratorio

- **RESULTADO_PCR** y **RESULTADO_PCR_COINFECCION**:
  - **Influenza**: 1 (AH1N1 PMD), 2 (A H1), 3 (A H3), 4 (B), 13 (A NO SUBTIPIFICADA), 14 (A H5).
  - **Coronavirus**: 22 (CORONA 229E), 23 (CORONA OC43), 24 (CORONA SARS), 25 (CORONA NL63), 26 (CORONA HKU1), 34 (SARS-CoV-2), 35 (MERS-CoV), 36 (SARS-CoV).
  - **Otros virus respiratorios**: 7 (ADENOVIRUS), 8 (PARAINFLUENZA 1), 9 (PARAINFLUENZA 2), 10 (PARAINFLUENZA 3), 32 (PARAINFLUENZA 4), 11 (VSR), 20 (VSR A), 21 (VSR B), 28 (ENTEROV//RHINOVIRUS), 29 (METAPNEUMOVIRUS), 37 (BOCAVIRUS).
  - **Resultados técnicos y de control**: 5 (NEGATIVO), 6 (MUESTRA NO ADECUADA), 17 (MUESTRA RECHAZADA), 27 (MUESTRA QUE NO AMPLIFICÓ), 30 (MUESTRA SIN AISLAMIENTO), 33 (MUESTRA SIN CÉLULAS), 41 (MUESTRA NO RECIBIDA), 997 (NO APLICA, CASO SIN MUESTRA), 998 (SIN COINFECCIÓN), 999 (PENDIENTE).
- **RESULTADO_ANTIGENO**:
  - 1: POSITIVO A SARS-COV-2 | 2: NEGATIVO A SARS-COV-2 | 97: NO APLICA (CASO SIN MUESTRA)

Clasificaciones epidemiológicas finales

- **CLASIFICACION_FINAL_COVID**:
  - 1: CASO DE COVID-19 CONFIRMADO POR ASOCIACIÓN CLÍNICA EPIDEMIOLÓGICA
  - 2: CASO DE COVID-19 CONFIRMADO POR COMITÉ DE DICTAMINACIÓN
  - 3: CASO DE SARS-COV-2 CONFIRMADO (POR PCR O ANTÍGENO)
  - 4: INVÁLIDO POR LABORATORIO
  - 5: NO REALIZADO POR LABORATORIO
  - 6: CASO SOSPECHOSO
  - 7: NEGATIVO A SARS-COV-2
- **CLASIFICACION_FINAL_FLU**:
  - 3: CASO DE INFLUENZA CONFIRMADO
  - 4: INVÁLIDO POR LABORATORIO
  - 5: NO REALIZADO POR LABORATORIO
  - 6: CASO SOSPECHOSO
  - 7: NEGATIVO A INFLUENZA

4.2. Cambios metodológicos y exploración de los datos

En las revisiones del sistema se registran dos evoluciones estructurales:

1. Sustitución de `RESULTADO_LAB`: se reemplazó la variable general anterior por la medición detallada a través de `RESULTADO_PCR` y `RESULTADO_PCR_COINFECCION`, lo que permite documentar la presencia de coinfecciones virales complejas.

2. Bifurcación de la clasificación final: la variable histórica de clasificación general se separó en `CLASIFICACION_FINAL_COVID` y `CLASIFICACION_FINAL_FLU`, para asegurar un seguimiento diferenciado e integral.

Dado que se cuenta con un archivo CSV por año, lo primero que se realizó fue concatenar las bases de datos, verificando que tuvieran la misma dimensión y que no existieran problemas al relacionar los datos de los diferentes años. El resultado de esta concatenación es un único archivo CSV que contiene los registros de 2020 a 2023. El total de registros es de 20,372,904.
Para manejar de forma más eficiente esta base de datos, y dado que la investigación se plantea bajo el modelo de un solo parche, se eliminaron del CSV conjunto las siguientes variables:

```
var_no_necesarias=['ORIGEN','SECTOR','ENTIDAD_UM','ENTIDAD_NAC','ENTIDAD_RES','MUNICIPIO_RES','EN
```

El resultado es un archivo CSV de aproximadamente 2 GB con más de veinte millones de registros.
En el análisis exploratorio se encontró que no existen valores nulos ni registros duplicados.
La distribución de la clasificación final presenta los siguientes valores:

Clave	Clasificación final	Registros
7	Negativo a SARS-CoV-2	11,791,076
3	Caso de SARS-CoV-2 confirmado	7,319,704
6	Caso sospechoso	757,457
1	Caso confirmado por asociación clínica epidemiológica	377,706
5	No realizado por laboratorio	98,902
2	Caso confirmado por comité de dictaminación	15,995
4	Inválido por laboratorio	12,064

En este periodo se registraron 7,713,405 casos positivos (claves 1, 2 y 3) y 335,098 defunciones.
A partir de este punto, no es viable trabajar siempre con todo el CSV, por lo que se creó una función que, dadas una fecha inicial y una fecha final, genera un nuevo archivo que excluye los registros fuera de dicho rango. El filtrado se realiza con la variable `FECHA_INGRESO`.
Sin embargo, como es de esperarse, los datos reportados presentan algunas situaciones que deben analizarse. La primera es que, desde el sentido común, es probable que dichos datos no reflejen del todo el estado real de la epidemia, ya que no todas las personas acuden a centros de salud. Por ello, el registro que se tiene de los compartimentos de infectados, recuperados y fallecidos es menor al real.
Además, aunque existe un proceso estándar de registro, no debe perderse de vista que hay numerosas limitaciones para que este se realice de forma óptima. Situaciones como los retrasos en la actualización del estado de los pacientes, las demoras en los resultados de laboratorio e incluso los errores humanos provocan que el registro no sea del todo confiable.
Estas situaciones llevan a pensar que existe un proceso oculto, que es el que realmente ocurre, y otro que es el que se puede observar, el cual se encuentra sesgado. Esta manera de plantear el problema es la que permite utilizar la metodología de los filtros de Kalman.

Capítulo 5

Metodologia

Bibliografía

[1] Diario Oficial de la Federación. Decreto por el que se establece la regulación en materia de datos abiertos. Diario Oficial de la Federación, February 2015.

[2] G. T. H. Germán. Pandemias en la historia: la peste negra y la gripe española, COVID-19 y crisis capitalista. DSpace UNACH, August 2021.

[3] J. D. Murray. *Mathematical Biology*. Springer, 1989. En Springer eBooks.

[4] J. R. Norris. *Markov Chains*, volume 2 of *Cambridge Series in Statistical and Probabilistic Mathematics*. Cambridge University Press, Cambridge, 1997.

[5] Otto Peláez Sánchez and Pedro Más Bermejo. Brotes, epidemias, eventos y otros términos epidemiológicos de uso cotidiano. *Revista Cubana de Salud Pública*, 46(2):e2358, 2020. ISSN 1561-3127.

[6] Ilse Valencia. Así fue la evolución del coronavirus en méxico. Gaceta UNAM, March 2025.

[7] Emilia Vynnycky and Richard G. White. *An Introduction to Infectious Disease Modelling*. Oxford University Press, 2010.